



Francesco Hayez, *Ritratto di Alessandro Manzoni*, 1841, Pinacoteca di Brera (opera di dominio pubblico)

Diario del progetto

Il tono della peste: mappare le emozioni nei Promessi Sposi


Documento di accompagnamento: descrive passo per passo il lavoro svolto per realizzare il progetto, incluse le difficoltà tecniche incontrate durante la raccolta dei dati e il modo in cui sono state risolte.



Schema del flusso di lavoro seguito, dalla raccolta dei dati all'estensione finale.

Introduzione

Questo documento racconta, in ordine cronologico, tutto il percorso seguito per realizzare il progetto: dalla preparazione del computer, alla ricerca e pulizia dei dati, fino all'analisi e alla visualizzazione dei risultati. Include anche i tentativi falliti e i problemi tecnici incontrati lungo il percorso, perché fanno parte del metodo di lavoro descritto nella dispensa del corso: il primo tentativo raramente funziona alla perfezione, e il ciclo "provare - ispezionare - correggere" è normale, non un segno di errore.



Screenshot: l'ambiente di lavoro in VS Code, con tutti i file del progetto nella barra laterale e il codice dello script di analisi del sentiment aperto.

Domanda di ricerca, ipotesi e titolo del progetto

Titolo del progetto (personale, come richiesto dalla consegna): *"Il tono della peste: mappare le emozioni nei Promessi Sposi"*.

Domanda di ricerca: l'andamento del tono emotivo nei capitoli dei Promessi Sposi rispecchia i momenti narrativamente più drammatici del romanzo (in particolare la peste e la morte di don Rodrigo)? Un metodo automatico di sentiment analysis, per quanto semplice, è in grado di "riconoscere" questi momenti chiave tanto quanto un lettore umano che conosce la trama?

Ipotesi: i capitoli corrispondenti agli eventi narrativamente più drammatici (in particolare i capitoli della peste, XXXI-XXXIV) mostrano un punteggio emotivo nettamente più negativo rispetto ai capitoli circostanti, e il punteggio torna positivo verso la fine del romanzo, in corrispondenza della risoluzione della trama.

Fase preliminare — Preparazione del computer

Prima di poter scrivere qualsiasi script, è stato necessario installare sul Mac gli strumenti di base per programmare in Python.

- **Python:** scaricato dal sito ufficiale python.org/downloads (non va usato il Python preinstallato da Apple, non adatto allo sviluppo) e installato con il pacchetto .pkg per macOS.
- **Visual Studio Code (VS Code):** l'editor in cui si scrive e si esegue il codice, scaricato da code.visualstudio.com.
- **Estensione Python per VS Code:** installata dal pannello Estensioni dentro VS Code, aggiunge colori al codice e il terminale integrato.
- **Strumenti da riga di comando di Apple (Command Line Tools):** richiesti automaticamente dal sistema durante l'installazione, necessari per il corretto funzionamento di alcuni strumenti di sviluppo.

Verifica finale: nel Terminale, il comando `python3 --version` ha restituito `Python 3.14.7`, confermando che l'installazione era andata a buon fine.

È stata poi creata una cartella di progetto dedicata (`promessi-sposi-progetto`), aperta in VS Code con `File → Open Folder`: è la cartella che contiene tutti gli script e i dati del progetto, e che verrà caricata su GitHub.

Fase 0 — Procurarsi il testo

Obiettivo: ottenere il testo completo dei Promessi Sposi in un formato utilizzabile da uno script Python. Questa fase si è rivelata la più complicata, per motivi di connessione di rete, ed è raccontata qui in dettaglio perché il modo in cui è stata risolta è di per sé un esempio del metodo di lavoro richiesto dal progetto: quando una fonte di dati non funziona, si documenta il problema, si cerca un'alternativa valida, e si motiva la scelta.


Tentativo 1 — Project Gutenberg (fallito)

La prima fonte scelta è stata Project Gutenberg, un archivio di testi di pubblico dominio molto usato anche nella dispensa del corso. È stato scritto un primo script che scaricava il testo con la libreria `requests` da un link diretto (`gutenberg.org/ebooks/45334.txt.utf-8`).

Eseguendo lo script è comparso un errore di tipo `ConnectTimeout`: il computer non riusciva proprio a raggiungere il sito. Lo stesso problema si è verificato anche aprendo il link direttamente nel browser Safari.

Diagnosi effettuata, per capire se il problema fosse generale o specifico:

- `ping -c 3 gutenberg.org` → nessuna risposta (ma il ping è spesso bloccato apposta dai server, quindi non è una prova definitiva da sola).
- `curl -I https://www.google.com` → risposta corretta e immediata: la connessione internet in generale funzionava benissimo.
- `curl -I https://www.gutenberg.org` → errore "Failed to connect... Couldn't connect to server" dopo 75 secondi di attesa: conferma definitiva che il problema era specifico di quel sito, raggiungibile invece da altre reti (per esempio nella navigazione fatta in parallelo per la ricerca di informazioni).



```
margheritab: curl
url -I https://www.gutenberg.org
curl: (28) Failed to connect to www.gutenberg.org port 443 after 75003 ms:
: Couldn't connect to server
margheritabaravalle@MacBook-Air-di-Margherita promessi sposi progetto % c
url -I https://www.gutenberg.org
```

Screenshot: l'errore restituito dal comando curl, prova diretta dell'irraggiungibilità di gutenberg.org dalla rete usata.

Il problema non dipendeva dal computer, da Python o dal codice scritto, ma da un'incompatibilità tra la rete usata e il dominio gutenberg.org (un fenomeno che può verificarsi con alcuni provider italiani verso determinati server esteri). Si è quindi deciso di cambiare fonte dei dati.

Tentativo 2 — Wikisource, pagina per pagina (fallito)

Come seconda fonte è stato scelto Wikisource (it.wikisource.org), verificato raggiungibile con successo tramite `curl -I`. Il testo su Wikisource è organizzato come centinaia di pagine web separate, una per ogni pagina del libro stampato originale (per esempio `.../Pagina:I_promessi_sposi_(1840).djvu/12`).

È stato scritto uno script che visitava in sequenza fino a 700 di queste pagine (con una breve pausa tra una richiesta e l'altra, per non sovraccaricare il server), estraendo il testo con la libreria BeautifulSoup.

Primo errore: tutte le pagine restituivano un errore HTTP 403 ("accesso negato"). Causa individuata: Wikipedia/Wikisource blocca le richieste automatiche che non si identificano correttamente (lo script Python, di default, non invia alcuna informazione su chi sta facendo la richiesta). Soluzione: aggiunta al codice di un header User-Agent personalizzato, che identifica lo script come uno strumento didattico legittimo.

Secondo errore: risolto il blocco 403, le pagine venivano scaricate correttamente (status 200), ma lo script non trovava il testo al loro interno: il codice cercava un elemento HTML con classe `pagetext`, ma il nome esatto di quell'elemento nella struttura reale della pagina non corrispondeva. A questo punto, per evitare di continuare a indovinare la struttura esatta pagina per pagina (un processo lento e non garantito), si è deciso di cambiare ancora fonte.

Soluzione finale — PDF Liber Liber da mirror universitario

La fonte definitiva scelta è stata un file PDF contenente il testo completo dell'edizione Liber Liber dei Promessi Sposi (a cura di Angelo Marchese), ospitato su un mirror del Politecnico di Torino (`linux.studenti.polito.it`), verificato raggiungibile e funzionante.

Lo script finale scarica il PDF con `requests` ed estrae il testo da tutte le sue pagine con la libreria `pypdf`, salvando il risultato in un file di testo semplice (`promessi_sposi_grezzo.txt`).

Risultato: 312 pagine PDF estratte correttamente, per un totale di 1.327.063 caratteri — l'intero romanzo.

La consegna del progetto richiede di motivare la scelta delle fonti e di dichiararne i limiti. Documentare il percorso reale, comprese le fonti scartate e il relativo motivo, è più rigoroso che presentare solo la soluzione finale come se fosse stata individuata immediatamente.

Fase 1 — Pulizia del testo

Prima di procedere, il testo grezzo è stato ispezionato a occhio: sono state individuate due anomalie principali.

- Un blocco iniziale di materiale editoriale di Liber Liber (titolo, licenza, note sull'edizione elettronica) che non fa parte del romanzo vero e proprio.
- Numeri di pagina del libro originale rimasti "incastrati" nel testo durante l'estrazione dal PDF, comparendo come righe isolate contenenti solo un numero (per esempio una riga con scritto solamente "155" nel mezzo di un paragrafo).

Lo script di pulizia (`pulisci_testo.py`) rimuove tutto ciò che precede la parola "INTRODUZIONE" (l'inizio reale del testo di Manzoni) e cancella, con un'espressione regolare, tutte le righe composte esclusivamente da uno o più spazi seguiti da un numero.

Risultato: rimosse 309 righe con soli numeri di pagina (un numero coerente con le 312 pagine del PDF originale). Testo pulito salvato in un nuovo file separato (`promessi_sposi_pulito.txt`), mantenendo intatto il file grezzo originale per tracciabilità.


Verifica manuale: controllato che il file iniziasse correttamente con "INTRODUZIONE" e che il numero "155" precedentemente trovato in mezzo al testo fosse effettivamente scomparso, senza alterare il testo circostante.

Divisione in capitoli

Per poter calcolare un punteggio emotivo capitolo per capitolo (e non per l'intero libro insieme), il testo pulito è stato diviso in 38 parti separate.

Metodo: individuate, tramite un'espressione regolare (`CAPITOLO\s+([IVXLCDM]+)`), tutte le intestazioni nella forma "CAPITOLO" seguito da un numero romano (verificato in precedenza che l'edizione usa sempre i numeri romani, incluso per il primo capitolo: "CAPITOLO I"). Il testo tra un'intestazione e la successiva costituisce il contenuto di ciascun capitolo. Il risultato è stato salvato in un file strutturato (`capitoli.json`), con numero progressivo, numero romano e testo per ciascun capitolo.

Verifica: lo script ha trovato esattamente 38 capitoli, corrispondente al numero reale di capitoli del romanzo — conferma indiretta che la segmentazione ha funzionato correttamente.



Screenshot: struttura del file capitoli.json, con numero, numero romano e testo per ciascun capitolo.

Fase 2 — Analisi del sentiment

Scelta del metodo: tra le due opzioni possibili (una libreria Python locale basata su un dizionario di parole, oppure l'API di un modello linguistico), è stata scelta la prima, per privilegiare semplicità, assenza di costi e di configurazioni aggiuntive (account, chiave API), pur mantenendo un metodo scientificamente valido e facilmente spiegabile.

È stato costruito manualmente un dizionario di circa 75 parole italiane positive (per esempio "gioia", "speranza", "pace") e 75 negative (per esempio "paura", "morte", "peste", "dolore"), scelte pensando al lessico tipico della narrativa ottocentesca.

Per ciascun capitolo, lo script:

- divide il testo in parole singole, tutte minuscole e senza punteggiatura (tokenizzazione);
- conta quante parole del capitolo compaiono nell'elenco delle parole positive e quante in quello delle parole negative;
- calcola un punteggio come differenza tra positive e negative, **normalizzato ogni 1000 parole** — passaggio necessario perché i capitoli hanno lunghezze molto diverse tra loro, e senza normalizzazione i capitoli più lunghi apparirebbero artificialmente più "carichi" emotivamente solo per il fatto di contenere più parole in totale.

Il risultato è stato salvato in un file `sentiment_capitoli.csv`, con una riga per capitolo (numero, numero di parole totali, parole positive trovate, parole negative trovate, punteggio finale).

Fase 3 — Visualizzazione dei risultati

È stato creato un grafico a barre (libreria `matplotlib`) con il punteggio di ciascuno dei 38 capitoli, colorando in rosso i punteggi negativi e in verde quelli positivi, ed evidenziando con etichette alcuni capitoli chiave della trama scelti in anticipo (rapimento di Lucia, conversione dell'Innominato, inizio della peste, morte di don Rodrigo), per poter confrontare visivamente il risultato automatico con la conoscenza della trama.

Risultati principali osservati:




Grafico: andamento del punteggio emotivo capitolo per capitolo, con i capitoli chiave della trama evidenziati.

- I capitoli XXXI-XXXIV (la sezione della peste) sono risultati i più negativi di tutto il romanzo, con il capitolo XXXI (-9.28) come punto più basso in assoluto.
- Dal capitolo XXXV in poi il punteggio torna positivo, coerentemente con l'avvio della risoluzione della trama e il progressivo lieto fine.
- Il punteggio più alto di tutto il romanzo si trova invece al capitolo XXIII (+6.8), dentro una fascia stabilmente positiva che comprende i capitoli XXII-XXVI. Questa fascia corrisponde alla parte del romanzo successiva alla liberazione di Lucia dall'Innominato (capitolo XXIII), quando Lucia viene accolta da donna Prassede e incontra il cardinale Federigo Borromeo: un tratto di narrazione più disteso, prima della svolta drammatica della peste. Questo picco non era stato individuato in anticipo tra i "capitoli chiave" scelti prima dell'analisi (si era guardato solo a rapimento, conversione, peste e morte di don Rodrigo): è quindi un risultato osservato a posteriori, non confermato da un'aspettativa precedente, e va per questo trattato con un po' più di cautela interpretativa rispetto agli altri.

Questo risultato ha confermato l'ipotesi di partenza: anche un metodo automatico semplice, senza alcuna conoscenza incorporata della trama, è stato in grado di individuare correttamente uno dei momenti narrativamente più cupi del romanzo.

Fase 4 — Letteratura scientifica

Sono stati individuati due riferimenti pertinenti:

- **Reagan et al. (2016)**, "The emotional arcs of stories are dominated by six basic shapes": applica la sentiment analysis lessicale a migliaia di opere letterarie, individuando alcune "forme" emotive ricorrenti nell'andamento delle storie — la stessa logica di analisi applicata in questo progetto, su scala più piccola.
- **Rebora (2020)**, "Shared Emotions in Reading Pirandello. An Experiment with Sentiment Analysis": esperimento condotto su un testo letterario italiano, utile per il confronto diretto (stessa lingua, stesso dominio letterario) e per la discussione dei limiti del metodo su testi in italiano.

Da Reagan et al. emerge anche un'osservazione metodologica importante: i metodi a dizionario funzionano spesso peggio della casualità su singole frasi isolate, un problema che si attenua lavorando su porzioni di testo più ampie — il che giustifica la scelta di questo progetto di analizzare interi capitoli anziché singole frasi.

Estensione — Confronto tra il percorso emotivo di tre personaggi

Come approfondimento facoltativo, l'analisi è stata estesa dal livello dell'intero capitolo al livello del singolo personaggio, per verificare se Renzo, Lucia e l'Innominato mostrano andamenti emotivi diversi lungo il romanzo.

Metodo

Per ciascun capitolo, il testo è stato diviso in singole frasi (usando i punti di fine frase come separatori). Sono state poi isolate, per ciascun personaggio, solo le frasi in cui compare il suo nome o una variante (Renzo: "Renzo", "Tramaglino"; Lucia: "Lucia", "Mondella"; Innominato: "Innominato"). Sul testo così isolato è stato calcolato lo stesso punteggio di sentiment usato nella Fase 2 (stesso dizionario, stessa normalizzazione ogni 1000 parole), per restare pienamente confrontabile con l'analisi generale. I capitoli in cui un personaggio non compare sono stati esclusi dal grafico per quel personaggio.

Risultati

Il pattern più rilevante emerge attorno ai capitoli XIX-XXI: l'Innominato tocca il suo punto più alto al capitolo XIX (+10.2), per poi crollare insieme a Lucia al capitolo XXI (Innominato -6.9, Lucia -9.4) — esattamente il momento della trama in cui avviene la notte di crisi e tormento dell'Innominato, innescata dal rapimento di Lucia da lui ordinato al capitolo XX. Dal capitolo XXII in poi l'Innominato risale a valori stabilmente positivi, coerentemente con la sua conversione.




Grafico: andamento del punteggio emotivo di Renzo, Lucia e l'Innominato lungo i capitoli del romanzo.

Verifica di affidabilità statistica

Prima di considerare questi risultati robusti, è stato controllato quante frasi sostengono ciascuna osservazione, perché un punteggio calcolato su pochissime frasi può oscillare fortemente per la presenza o assenza di una sola parola del dizionario.

Osservazione	Frasi	Parole	Affidabilità
Lucia, cap. V (punto basso)	4	52	Bassa
Renzo, cap. X (punto basso)	1	48	Bassissima
Renzo, cap. XXV (punto alto)	2	69	Bassa
Innominato, cap. XIX (punto alto)	2	98	Bassa
Innominato, cap. XXI (crollo)	11	289	Discreta
Lucia, cap. XXI (crollo)	20	532	Buona

Questa verifica mostra un punto metodologico importante: i picchi isolati nei primi capitoli del romanzo (dove i personaggi compaiono ancora poco, in poche frasi per capitolo) sono statisticamente poco solidi e vanno citati con cautela — bastano una o due parole del dizionario a spostare il punteggio in modo consistente. Il pattern del capitolo XXI, essendo basato su un numero di frasi molto più alto (11 e 20), è l'osservazione più solida dell'intera estensione, ed è anche quella narrativamente più significativa.

L'affidabilità di ciascuna osservazione è stata verificata esplicitamente, controllando quanti dati la sostenessero, prima di attribuirle peso nelle conclusioni.

Limiti del metodo

È importante essere espliciti sui limiti di questo approccio, per due motivi: mostra consapevolezza critica (richiesta esplicitamente dalla consegna del progetto) e anticipa possibili domande in sede d'esame.

- **Dizionario limitato:** l'elenco di parole positive/negative usato (circa 150 parole totali) è una scelta manuale e non esaustiva. Molte espressioni emotive del romanzo, soprattutto quelle indirette o metaforiche, non vengono catturate.
- **Nessuna gestione della negazione:** la frase "non provava alcuna gioia" viene comunque conteggiata come positiva per la presenza della parola "gioia", anche se il significato reale è negativo. È un limite noto di tutti i metodi a dizionario semplice.
- **Nessuna comprensione del contesto o dell'ironia:** il metodo conta parole isolate, senza capire il senso della frase in cui compaiono.
- **Lessico ottocentesco vs. dizionario moderno:** il dizionario è stato costruito pensando all'italiano contemporaneo; alcune espressioni tipiche della prosa manzoniana potrebbero non essere ben rappresentate.
- **Un solo metodo:** non essendoci stato un confronto con un secondo metodo indipendente (per esempio l'analisi tramite un LLM via API), non si può escludere che parte del risultato osservato dipenda da caratteristiche specifiche di questo dizionario piuttosto che da un segnale emotivo reale e robusto.
- **Campioni di testo piccoli per l'estensione sui personaggi:** come verificato esplicitamente (si veda la tabella nella sezione Estensione), alcuni picchi si basano su una sola frase e vanno quindi considerati poco affidabili.

Conclusioni

Nonostante i limiti descritti, il progetto mostra che anche un metodo di sentiment analysis molto semplice ed economico da implementare è in grado di individuare correttamente, senza alcuna conoscenza pregressa della trama, uno dei momenti narrativamente ed emotivamente più rilevanti dei Promessi Sposi (la peste). Questo risultato supporta l'ipotesi di partenza e si allinea con quanto osservato in letteratura su altre opere letterarie (Reagan et al., 2016).

L'estensione sul confronto tra personaggi rafforza ulteriormente questa conclusione: applicato a un livello di analisi più fine (il singolo personaggio anziché il capitolo intero), lo stesso metodo individua un secondo momento chiave della trama — la crisi dell'Innominato e di Lucia al capitolo XXI — e lo fa in modo tanto più credibile quanto più ampio è il campione di testo disponibile, un aspetto verificato esplicitamente e non solo assunto.

In sintesi, la risposta alla domanda di ricerca è positiva, con le cautele discusse: sì, l'andamento del tono emotivo nei capitoli dei Promessi Sposi rispecchia i momenti narrativamente più drammatici del romanzo, e un metodo automatico anche semplice è in grado di individuarli. Il metodo, proprio per la sua semplicità e trasparenza, si presta bene a un'analisi didattica come questa, dove l'obiettivo non è la massima accuratezza possibile ma la comprensione critica di cosa un metodo computazionale può e non può cogliere di un testo letterario.